

Dataset: https://drive.google.com/file/d/1A4QDD-n3XQIGNyXNI8Kh2qnTACvPPOPO/view?usp=drive_link

1. Ausgangslage

StadtWerke Westhafen GmbH ist ein städtischer Energieversorger im Hamburger Hafengebiet. Versorgt werden 700 gewerbliche, industrielle und kommunale Großkunden über Mittel- und Niederspannungsanschlüsse. Der Gesamtjahresumsatz liegt bei rund 180 Mio. EUR.

Zwei operative Probleme sind in den letzten zwei Jahren gewachsen:

1. **Beschaffungsplanung:** Die monatliche Strombeschaffung erfolgt vorausschauend. Schlechte Verbrauchsprognosen führen zu kostspieligen Spotmarkt-Käufen oder Verkäufen.
2. **Anomalien:** Ungewöhnlich hoher oder niedriger Verbrauch ist häufig ein Hinweis auf Defekte, undetektierte Leitungsverluste, falsch ausgelesene Zähler oder Abrechnungsfehler. Aktuell werden Anomalien meist erst beim Quartalsabschluss bemerkt — manchmal Monate zu spät.

Die Geschäftsführung möchte ein **Vorhersage- und Frühwarn-Modell**, das auf Basis historischer Verbrauchsdaten, Wettereinflüssen und Produktionsplänen pro Zähler den voraussichtlichen Monatsverbrauch schätzt und Abweichungen zwischen Prognose und tatsächlichem Verbrauch als Anomalien markiert.

2. Auftrag an Ihre Gruppe

1. Den **Ist-Zustand** der Energieverbrauchs-Daten analysieren und die Datenqualität bewerten.
2. Ein **Machine Learning Canvas** für ein zweistufiges Modell (Prognose + Anomalie-Erkennung) entwickeln.
3. Die Daten **bereinigen, transformieren und visualisieren**.
4. Ein **Regressionsmodell** trainieren, das den Monatsverbrauch pro Zähler vorhersagt — und auf Basis der Residuen Anomalien markieren.
5. Ihre Erkenntnisse für Beschaffung und Asset-Management dokumentieren und präsentieren.

3. Stakeholder

Person	Rolle	Erwartung
Stefan Lechtenberg	Bereichsleiter Energiebeschaffung (Sponsor)	Genaue Verbrauchsprognose für den Folgemonat zur Optimierung der Beschaffung
Anke Bürger	Leiterin Netzmanagement	Anomalie-Hinweise pro Zähler für schnellere Wartungsentscheidungen
Henrik Maaß	Senior-Datenanalyst	Will eine reproduzierbare Pipeline und nachvollziehbare Anomalie-Definition

4. Die Daten

- **Datei:** data/verbrauch.csv
- **Umfang:** rund 16.800 monatliche Verbrauchsbeobachtungen (700 Zähler × 24 Monate)

- **Zeitraum:** Januar 2024 bis Dezember 2025
- **Encoding:** UTF-8 (mit BOM)

Datenwörterbuch

Spalte	Typ	Beschreibung
zaehler_id	Text	Eindeutige Zählerkennung
kunde_id	Text	Kundennummer
kundentyp	Text	Gewerbe, Industrie, Kommunal (teilweise abweichend geschrieben)
vertragsleistung_kw	Ganzzahl	Vertraglich vereinbarte Anschlussleistung in kW
monat	Text	Monat (gemischtes Format)
monat_idx	Ganzzahl	Monatszahl 1–12 (für Saisonalität)
arbeitstage	Ganzzahl	Werktage im Monat
feiertage_im_monat	Ganzzahl	Anzahl gesetzlicher Feiertage
mittlere_temperatur_c	Zahl	Mittlere Außentemperatur des Monats in °C
heiztage	Ganzzahl	Heizgrad-Tage (vereinfachte Variante)
produktionsplan_index	Zahl	Kundenspezifischer Produktionsplan-Index (1.0 = Normalmonat)
wartung_aktiv	Ganzzahl (0/1)	1 = Wartung / Stillstand im Monat
vormonat_verbrauch_kwh	Zahl	Verbrauch im Vormonat (NaN für den ersten Monat)
letzte_3_monate_durchschnitt_kwh	Zahl	Gleitender 3-Monats-Durchschnitt
vorjahr_monat_verbrauch_kwh	Zahl	Verbrauch im gleichen Monat des Vorjahres (NaN für 2024)
verbrauch_kwh	Gemischt	Zielvariable. Realisierter Monatsverbrauch in kWh (manche Werte als MWh-Text)

Wichtiger Hinweis zum zeitlichen Bezug

Alle Merkmale beschreiben Werte, die **zum Monatsbeginn bekannt sind**: Kundenmerkmale, Wettervorhersage, geplante Wartung, Produktionsplan-Index, sowie historische Verbrauchswerte (Vormonat, 3-Monats-Schnitt, Vorjahr). Die Zielvariable **verbrauch_kwh** ist der realisierte Monatsverbrauch.

Train/Test-Split

Wie bei Dataset 03 ist hier ein **zeitlicher Split** erforderlich:

- **Training:** Monate aus dem Jahr 2024
- **Test:** Monate aus dem Jahr 2025

5. Was im Bericht stehen muss

Die vier IHK-Standardkapitel.

Hinweis zum „Datenmodell“ in Kapitel 4

Einzelne Tabelle mit Zeitreihen-Struktur. „Datenmodell“ beschreibt: die bereinigte analytische Tabelle, neu konstruierte Features (z. B. `verbrauch_pro_arbeitstag`, `temperatur_anomalie`), die zeitliche Aufteilung von Trainings- und Testdaten, und die Anomalie-Definition (z. B. „absolute prozentuale Abweichung > 95-Perzentil-Schwelle“).

6. Vorschläge für die ML-Canvas-Felder

Feld	Vorschlag
Value Proposition / Mehrwert	Bessere Beschaffungsplanung und schnellere Erkennung anomaler Verbrauchsmuster
Data Sources / Datenquellen	Smart-Meter-Daten, Vertragsstammdaten, Wetterdienst, Produktionspläne, Wartungsplanung
Prediction / Vorhersage	Regression: Monatsverbrauch in kWh pro Zähler
Features / Merkmale	Vertragsleistung, Vormonat-Verbrauch, 3-Monats-Schnitt, Vorjahres-Monat, Arbeitstage, Heiztage, Mitteltemperatur, Produktionsplan-Index, Wartung, Kundentyp
Learning Approach / Lernansatz	Überwachte Regression (lineare Regression, Random Forest Regressor, Gradient Boosting)
Evaluation / Überprüfung	RMSE, MAE, R^2 auf der zeitlich getrennten Testperiode
Decision / Entscheidung	Prognose → Beschaffungsmengen. Residual > Schwelle → Anomalie-Ticket für Netzmanagement
Impact / Auswirkung	Reduzierte Spotmarkt-Kosten + schnelleres Erkennen von Defekten
Prediction Timing / Vorhersagezeitpunkt	Monatlich zum Monatsbeginn
Monitoring & Maintenance / Wartung	Quartalsweises Retraining; Drift-Monitoring auf Temperatur und Produktionsindex

7. Mögliche Leitfragen

- Welcher Kundentyp ist am schwersten zu prognostizieren?
- Wie stark trägt die Wetterabhängigkeit zur Vorhersage bei?
- Welche Monate haben die größten Restfehler — saisonale Übergänge?
- Wie viele Anomalien identifiziert das Modell pro Monat? Sind sie operativ plausibel?

8. Ethik- und Risiko-Hinweis

In dieser Domäne gibt es keine Personendaten im engeren Sinn. Risiken liegen aber in der Anomalie-Erkennung:

- Ein **falsch-positiver** Anomalie-Alarm (Modell flaggt einen normalen Monat) löst unnötigen Aufwand beim Netzmanagement aus.
- Ein **falsch-negativer** Fall (Modell erkennt echte Anomalie nicht) lässt Defekte länger unbemerkt.

Diskutieren Sie diesen Trade-off im Bericht und schlagen Sie eine Schwellwert-Politik vor. Erläutern Sie auch, dass das Modell **keine Abrechnungsentscheidung** ersetzt — es flaggt nur Untersuchungswürdiges.

9. Empfohlene Aufgabenverteilung pro Sprint

Sprint 1

- Brief lesen, Datensatz herunterladen
- Datenqualitätsprüfung
- Werkzeuge aufsetzen
- Kapitel 1 (Ist-Zustand) schreiben
- 3–5 User Stories formulieren
- ML-Canvas-Felder *Value Proposition* und *Data Sources* befüllen
- Sprint-Log starten

Sprint 2

- Daten bereinigen (Datumsformate, Tippfehler in `kundentyp`, gemischte Einheiten in `verbrauch_kwh` (MWh vs kWh), fehlende Werte, Duplikate, negative Verbräuche)
- Vollständiges ML Canvas
- Explorative Datenanalyse: Saisonalität, Temperaturabhängigkeit pro Kundentyp
- Workflow-Dokumentation beginnen
- Sprint-1-Retrospektive, Sprint 2 planen

Sprint 3

- Regressionsmodell trainieren mit zeitlichem Split
- Anomalie-Schwellwert definieren und begründen
- Feature Importance auswerten
- Dashboard / Visualisierungen
- Kapitel 3 und 4 ausarbeiten
- Bericht entwerfen und abgeben

Finalisierungsphase

- Bericht-Feinschliff
- Live-Demo einüben
- Gruppenpräsentation und Fachgespräch üben
- Mock-Prüfung

10. Werkzeug-Empfehlung

- **Tableau** für Dashboards (Heatmaps, Saisonalität)
- **Python** für Bereinigung, Feature Engineering, Modellierung, Anomalie-Erkennung
- **SQL** für aggregierte Auswertungen
- Google Sheets für Sprint-Log

11. Erfolgskriterien

Ihr Projekt ist erfolgreich, wenn am Ende:

- Die Daten sauber bereinigt sind, einschließlich der MWh/kWh-Vereinheitlichung

- Der Train/Test-Split zeitlich erfolgt und im Bericht erklärt ist
- Das ML Canvas alle 10 Felder kohärent ausfüllt
- Ein Regressionsmodell mit sinnvollen Metriken (RMSE, MAE, R^2) bewertet wurde
- Eine begründete Anomalie-Schwellwert-Definition vorliegt
- Eine klare Aussage über die Treiber des Energieverbrauchs existiert
- Jedes Gruppenmitglied seine Sektion eigenständig im Fachgespräch verteidigen kann

Wann ist die IHK-Prüfung bestanden?

≥ 50 % unabhängig im schriftlichen Bericht (70 Punkte) UND in der mündlichen Prüfung (30 Punkte).

Viel Erfolg.