


ML Canvas: vom Nutzen zum Modell und zurück



 Was kostet es, wenn das Modell falsch liegt?

Fehler kosten Spotmarkt-Ausgleich oder Prüfzeit



Euro-Beträge sind nicht belegt: Spotmarkt-Kosten, Prüfzeit und Bestätigungsquote misst der Pilot (Bericht, Canvas-Feld 08).

04

Methodik und Modell

 ZL-00147 · August 2025

gemessen

23.563 kWh

erwartet **7.304** kWh · gut das Dreifache

 Bisher: fällt erst in der Quartalsauswertung auf

 Neu: Prüfhinweis direkt nach Monatsende

Wie wird aus Daten ein Prüfhinweis?

VOR MONATSBEGINN · PROGNOSE → Beschaffung (S. Lechtenberg)



1 Vergangenheit

Nur Informationen, die vor dem Prognosemonat bekannt sind.



2 Modell

Random Forest schätzt die Vollaststunden (VLS) des Folgemonats.



3 Rückrechnung

Prognose-VLS × Vertragsleistung = Prognose in kWh.



MONAT LÄUFT

NACH MONATSENDE · PRÜFUNG → Netzmanagement (A. Bürger)



4 Istwert

Nach Monatsende kommt der gemessene Verbrauch.



5 Residuum

Ist minus Prognose, bezogen auf die Anschlussgröße.




6 Prüfhinweis

Nur über der Schwelle prüft ein Mensch · Export ins Dashboard (JSON).

 User Story Henrik Maaß: reproduzierbarer Workflow mit dokumentierter Schwelle

Vergangenheit erklärt Zukunft, niemals umgekehrt



3-Monats-Mittel neu berechnet

Die gelieferte Spalte enthielt spätere Werte (Leakage). Jetzt je Zähler nur abgeschlossene Monate.



Pipeline je Fold

Auch das Auffüllen fehlender Werte lernt nur aus dem jeweiligen Lernblock.



2025 entscheidet nichts

Modell, Einstellungen und Schwelle stehen fest, bevor 2025 bewertet wird.



NICHT IM MODELL

Vorjahr: keine Historie 2023

Temperatur ≈ Heizgradtage

„anomalie“: kein Label

Vertragsleistung: nur Umrechnung



Das Modell lernt Volllaststunden, geplant wird in kWh

÷ NORMIEREN

$$\text{VLS} = \frac{\text{Verbrauch [kWh]}}{\text{Vertragsleistung [kW]}}$$

📊 ZURÜCKRECHNEN

$$\text{Prognose [kWh]} = \text{Prognose-VLS} \times \text{kW}$$


📈 Aus unseren Daten

92 % der Streuung im Rohverbrauch liegen zwischen den Zählern. In VLS liegen die Kundentyp-Mediane nur noch bei 160–173 h.




Wie bei Hotels: Man vergleicht die Auslastung, nicht die Gästezahl.

Energiemenge
in kWh



Volllaststunden
in VLS-h




-6,2 %

Test-RMSE gegenüber einem gleich
abgestimmten, direkt auf kWh trainierten
Random Forest
9.800 → 9.188 kWh

Random Forest knapp vorn, einfache Regeln klar geschlagen


Auswahl · Ø RMSE über 3 zeitliche Folds 2024



Fold 1 liegt überall am höchsten und zieht jeden Mittelwert hoch. Strich = ±1 Std.

Bestätigung · RMSE im Testjahr 2025

gleiche Skala wie links



$RMSE = \sqrt{\frac{1}{n} \sum (Ist - Prognose)^2}$ · bestraft große Fehler, die am Spotmarkt teuer sind

-15,9%

weniger RMSE als die beste einfache Regel
Test 2025: 10.922 → 9.188 kWh

TESTJAHR 2025



RMSE 9.188 kWh · **MAE** 3.725 kWh · **R²** 0,901

R² ist keine Trefferquote.

TOP-3-TREIBER · PERMUTATION, KWH



Verbrauchshistorie **+7.256**
Produktionsplan **+798**
Wartung **+591**

betrieblich plausibel, keine Kausalität

Aus dem Prognosefehler wird ein Prüfhinweis



RESIDUUM

$$r = \frac{\text{Ist} - \text{Prognose [kWh]}}{\text{Vertragsleistung [kW]}}$$



SCHWELLE

q99 = 144,4 VLS-h

99. Perzentil der 1.397 Fehlerbeträge Nov-Dez 2024



FAKTOR

$$F = r \div q99$$

$F \geq +1$ oder $F \leq -1 \Rightarrow$ Prüfhinweis · keine Wahrscheinlichkeit

Modellabweichung




Prüfhinweis



bestätigte Anomalie

Kalibrierung Nov-Dez 2024 · 1.397 Fehlerbeträge, der Größe nach sortiert

Fehlerbetrag in VLS-h



99 von 100 Vorwärtsfehlern waren kleiner als 144,4 VLS-h; 14 lagen darüber.



Das Modell ersetzt keine Abrechnungsentscheidung. Es markiert nur, was eine Prüfung wert ist.



Die Schwelle wird vor 2025 festgelegt und dann eingefroren



Vorwärts prognostizieren

November mit einem Modell aus Jan–Okt, Dezember aus Jan–Nov: 1.397 echte Prognosefehler.



Schwelle ableiten und einfrieren

99. Perzentil = 144,4 VLS-h. Danach wird sie nicht mehr verändert.



2025 nur anwenden

Das finale Modell (ganz 2024) prognostiziert, die feste Schwelle entscheidet: 114 Prüfhinweise.

WAS DIE KALIBRIERUNG FÜR 2025 BEDEUTET

Kalibriert Nov–Dez 2024 · gilt für 2025

 **144,4 VLS-h**

Nachträglich aus 2025 · wäre Leakage

 **175,1 VLS-h**

17,3 → 17,1

typischer Fehler (Median, VLS-h): gleich groß

1,36 %

über der festen Grenze statt 1 %: die Extreme sind 2025 größer


WARUM GERADE NOV–DEZ 2024?

- Jüngste Monate vor dem Testjahr
- Nicht für die Modellwahl genutzt (Folds enden im Oktober)
- Später geht nicht, ohne 2025 selbst zu verwenden



Kalibrieren ändert nur die Grenze, nicht Modell oder Prognose. Neu kalibriert wird erst, wenn Fehler oder Hinweisvolumen über mehrere Monate abweichen.

2025: 114 von 8.398 Zähler-Monaten liegen außerhalb



9,5

Prüfhinweise je Monat

rund 2 pro Woche · 114 Hinweise (1,36 %) bei 107 Zählern
68 ungewöhnlich hoch ↑ · 46 ungewöhnlich niedrig ↓

SENSITIVITÄT · HINWEISE JE MONAT 2025

q95
33,3
je Monat

q97,5
21,3
je Monat

q99
9,5
je Monat

q99,5
5,8
je Monat

← mehr Fehlalarme, weniger übersehen


weniger Fehlalarme, mehr übersehen →

q95 hieße 3,5-mal so viele Fälle wie q99. Wie viel geprüft wird, legt der Fachbereich fest.



Plausibilisierung ohne Labels: alle 10 physikalisch unmöglichen Werte 2025 markiert. Sanity Check, kein Qualitätsbeweis.

ZL-00147: Im August ist die Abweichung 2,3-mal so groß wie erlaubt



AUGUST 2025 · RECHENWEG

Ist – Prognose	23.563 – 7.304 kWh
Residuum	+16.259,6 kWh
in VLS (49 kW)	480,9 – 149,1 = 331,8
÷ Schwelle q99	144,4 VLS-h
Faktor	+2,30



September zum Vergleich

Faktor -0,68 → innerhalb der Grenze, kein Hinweis. Die Prognose ist erhöht, weil der August als Vormonat einfließt.

Prüfen, bewerten und aus dem Feedback lernen

Fallakte · Warum wurde der Fall markiert?

FALLAKTE

ZL-00147 · 08/2025

KD-747972 · ungewöhnlich hoch. Das Modell priorisiert den Fall; die Ursache wird fachlich geprüft.

Gewerbe

Faktor 2,30

Nicht bewertet

Zur Prüfwarteschlange

Bewertung dokumentieren

Ist 08/2025

23.563 kWh

Prognose 08/2025

7.304 kWh

Random Forest · Vollaststunden

Abweichung

+16.260 kWh

+222,6 % gegenüber Prognose

Schwellenfaktor

2,30

ab 1,00 · 99. Perzentil

Begründung

Warum wurde dieser Fall markiert?
Das VLS-Residuum beträgt +331,8 h und überschreitet damit die aus November und Dezember 2024 kalibrierte Grenze von ±144,4 VLS-Stunden. Das entspricht Faktor 2,30. Ist 23.563,49 kWh und Prognose 7.303,90 kWh unterscheiden sich um +16.259,59 kWh beziehungsweise +222,62 %.

Gespeichert · Status in der Prüfwarteschlange

Prüfwarteschlange

Nach Schwellenfaktor sortiert; absolute kWh-Auswirkung bleibt als betrieblicher Kontext sichtbar.

1 Treffer

Suche

Monat

Kundentyp

Richtung

Bearbeitungsstatus

Kontext

ZL-00147

08/2025

Alle Kundentypen

Beide Richtungen

Alle Status

Alle Kontexte

KUNDENTYP	RICHTUNG	FAKTOR ↓	IST (KWH)	PROGNOSE (KWH)	ABWEICHUNG (KWH) ↓	RESIDUUM (VLS-H) ↓	KONTEXT
Gewerbe	↑ ungewöhnlich hoch	2,30	23.563	7.304	+16.260	+331,8	—

Status

Bewertung abgeschlossen

Bewertung dokumentieren · Beispieleingabe

Bewertung dokumentieren

ZL-00147 · 08/2025 · Faktor 2,3

Getrennte Bewertungsdimensionen

Dokumentieren Sie Messwert, Erklärung und Handlungsbedarf getrennt. So entstehen später belastbare Labels; weder Ticket noch E-Mail werden versendet.

Bearbeitungsstatus

Bewertung abgeschlossen

Label-Quelle

Messwert gültig?

Ja

Abweichung erklärt?

Nein

Wahrscheinliche Ursache

Noch ungeklärt

Handlungsbedarf

Technische Prüfung

Verantwortliche Person oder Rolle

Technischer Kundenservice

Prüfnotiz

Messwert plausibel, kein Wartungs- oder Produktionskontext – Anomalie bestätigt.

Abbrechen

Lokal speichern

Messwert gültig = Ja + Abweichung erklärt = Nein ⇒ bestätigte Anomalie → Precision messen → Stichprobe für Recall → Klassifikation

Mein Fazit: Bei Zeitreihendaten ist die Validierung wichtiger als das komplexeste Modell.

→ Patrick: Ergebnisse & Empfehlungen

 Stimmt die Folie mit dem Bericht überein?

ML Canvas im Wortlaut von Tabelle A1



01 MEHRWERT

Genauere Folgemonatsplanung und monatliche Prüfung ungewöhnlicher Zählerwerte.



03 VORHERSAGE

VLS je Zähler-Monat; Rückrechnung in kWh; große Residuen werden Prüfhinweise.



05 LERNANSATZ

Überwachte Regression; lineare Regression als Referenz, Random Forest als nichtlinearer Vergleich.



07 ENTSCHEIDUNG

Prognose unterstützt Beschaffung; Hinweis führt zur menschlichen Prüfung.



09 ZEITPUNKT

Prognose vor Monatsbeginn; Residuenprüfung nach Eintreffen des Monatswerts.



02 DATENQUELLEN

Zählerverbräuche, Verträge, Kundentyp, Kalender, Wetter, Produktionsplan und Wartung.



04 MERKMALE

Historie, Saison, Kalender, Wetterprognose, Produktionsplan, Wartung und Kundentyp.



06 EVALUATION

RMSE in kWh als Hauptmetrik; MAE und R^2 ergänzend; Vergleich mit zwei Baselines.



08 IMPACT

Pilot-KPIs: Fehler, Hinweisvolumen, Prüfzeit und Bestätigungsquote.



10 MONITORING

Monatliche Fehler-, Drift- und Hinweiskontrolle; Retraining nur bei belegter Verschlechterung.



KOHÄRENZ

01 ↔ 08

gleiche Einheiten: kWh und Fälle pro Monat

09 → 04

nur Wissen, das vor Monatsbeginn vorliegt

03 → 05 → 06

Regression → RMSE in kWh

07 ↔ 09

Prognose vor, Prüfung nach Monatsende

Acht kontrollierte Kombinationen, entschieden nur in 2024

Baumtiefe	Merkmalsanteil	Min. Fälle je Blatt	CV-RMSE (kWh)	Fold-Streuung (Std., kWh)
8	0,7	5	13.272	3.843
unbegrenzt	0,7	5	13.331	3.849
8	1,0	5	13.355	3.757
unbegrenzt	1,0	5	13.422	3.729
unbegrenzt	0,7	20	13.473	4.021
8	0,7	20	13.481	4.015
8	1,0	20	13.549	3.941
unbegrenzt	1,0	20	13.565	3.923



Tiefe 8

Begrenzte Tiefe vermeidet sehr spezielle Einzelregeln.



Mindestens 5 Fälle je Blatt

Ein Blatt steht nicht nur für einen einzelnen Zähler-Monat.



70 % der Merkmale

Bäume sehen unterschiedliche Merkmale und ergänzen sich.

300 Bäume, random_state = 42. Die Unterschiede sind klein; entscheidend ist die zeitliche Prüfung.

Die Verbrauchshistorie trägt den Großteil der Prognose

Anstieg des Test-RMSE, wenn eine Gruppe gemischt wird (kWh, Bericht Tab. D1)



So liest man es

Steigt der Fehler stark, war die Information wichtig für die Prognose.



Plausibel

Historie, Produktionsplan und Wartung sind betriebliche Treiber; der Kundentyp steckt bereits in der Historie.



Grenze

Wichtigkeit ist keine Kausalität. Die Vertragsleistung wird nicht gemischt, sie ist der Umrechnungsfaktor.


Bericht Tab. D1 mit fünf Wiederholungen; Notebook 13 mit drei Wiederholungen zeigt dieselbe Rangfolge.



Wie entstehen die Historien-Merkmale?

Lag-Features verschieben bekannte Historie nach vorn

Erster Zähler im Datensatz · ZL-00000 · 2024 (VLS-h)



Januar 2024

Echter Kaltstart: keine Historie. Die Werte bleiben leer und werden im Fold aufgefüllt.



Februar und März

Nutzen die verfügbare Historie (1 bzw. 2 Monate).



Ab April

Mittel aus bis zu drei gültigen, abgeschlossenen Vormonaten (Umsetzung mit shift(1)).

So bleiben 1.453 Drei-Monats-Werte erhalten; nur 700 Januar-Kaltstarts sind leer.

Was wir belastbar sagen können und was noch Daten braucht



BELEGT

Prognose schlägt einfache Regeln

- RMSE 9.188 kWh, MAE 3.725 kWh
- -15,9 % gegenüber Ø bis zu 3 Vormonate
- Kein klares Overfitting-Signal



ENTSCHEIDUNG

q99 ist eine Pilotannahme

- 9,5 Hinweise pro Monat, 114 im Jahr 2025
- Per Regler verschiebbar, ohne Retraining
- Fachbereich legt die Kapazität fest



OFFEN

Keine Precision und Recall

- Prüfhinweis $\neq$ bestätigte Anomalie
- 2025 ist retrospektiv, kein Blindtest
- Pilot mit Bewertungen und Stichprobe liefert die Evidenz



VERANTWORTUNG

Der Mensch entscheidet

- Kundentypen Gewerbe, Industrie, Kommunal
- Bewertungen im Prototyp nur lokal
- Hinweisquote je Kundentyp im Pilot beobachten




Verfügbarkeit: Die Heizgradtage stehen vereinfachend für die Wetterprognose. Im Betrieb Prognose- und Planversionen zum Stichtag speichern.

Prüfaufwand statt ROI: belegte Mengen, keine erfundenen Euro

Prüfhinweise je Monat 2025 (q99)

--- Ø 9,5 je Monat



Worst Case beim Aufwand

q95 statt q99: 33,3 statt 9,5 Fälle im Monat, also 3,5-facher Prüfaufwand.



Rückfall

Ist das Modell im Pilot nicht besser: lineare Regression oder das Mittel der letzten drei Monate.



Im Pilot erfassen

Prüfzeit je Fall, Bestätigungsquote und Spotmarkt-Mengen. Erst daraus entsteht eine Euro-Rechnung.