

03/04

Machine Learning: vom Canvas zum Prüfhinweis

Was in diesem Teil beantwortet wird



Was sagt das Modell vorher, und womit?

Folie 2–4



Woran messen wir, ob es gut ist?

Folie 5–6



Ab wann wird eine Abweichung geprüft?

Folie 7–8

Kiko Ramon Lukas · Machine Learning und Evaluation

ML Canvas: sechs Felder gehören zum Modell

03 · VORHERSAGE

Was sagt das Modell vorher?

Den Stromverbrauch jedes Zählers im nächsten Monat, am Ende in kWh.

04 · MERKMALE

Womit rechnet es?

Nur mit Wissen vor Monatsbeginn: Verbrauchshistorie, Kalender, Wetter, Produktion, Wartung, Kundentyp.

05 · LERNANSATZ

Wie lernt es?

Aus Beispielen mit bekanntem Ergebnis: Random Forest gegen einfachere Verfahren.

06 · EVALUATION

Woran messen wir es?

Am RMSE in kWh, nur auf Monaten, die das Modell beim Lernen nicht kannte.

07 · ENTSCHEIDUNG

Was passiert mit dem Ergebnis?

Die Prognose geht in die Beschaffung; ungewöhnliche Abweichungen gehen zur Prüfung.

09 · ZEITPUNKT

Wann läuft es?

Zweimal im Monat: Prognose vor Monatsbeginn, Prüfung nach Monatsende.


01 Mehrwert · 02 Datenquellen

besprochen · Iana

08 Impact · 10 Monitoring

folgt · Patrick

Vergangenheit erklärt Zukunft, niemals umgekehrt



Jede Bewertung nutzt nur Monate, die davor liegen. Modell und Schwelle stehen fest, bevor 2025 bewertet wird.

Leakage vermieden

Das 3-Monats-Mittel wurde nur aus abgeschlossenen Monaten neu berechnet.

Das Modell lernt Volllaststunden, geplant wird in kWh

NORMIEREN

$$\text{VLS} = \text{Verbrauch [kWh]} \div \text{Leistung [kW]}$$


ZURÜCKRECHNEN

$$\text{Prognose [kWh]} = \text{VLS} \times \text{Leistung [kW]}$$


Warum?

92 % der Streuung im Rohverbrauch liegen zwischen den Zählern. In VLS werden große und kleine Anschlüsse vergleichbar.


Energiemenge
in kWh



Volllaststunden
in VLS-h



Warum RMSE? Er gewichtet große Fehler stärker



FORMEL

$$\text{RMSE} = \sqrt{(\sum (\text{Ist} - \text{Prognose})^2 \div n)}$$

$$\text{A: } \sqrt{(4 \cdot 10^2 \div 4)} = 10 \text{ kWh}$$


$$\text{B: } \sqrt{(40^2 \div 4)} = 20 \text{ kWh}$$

- Misst in kWh: der Einheit, in der die Beschaffung plant.
- Große Abweichungen gleicht die Beschaffung teuer am Spotmarkt aus.
- MAE und R^2 ergänzen, entscheiden aber nicht.

Random Forest gewinnt die Auswahl in 2024

Ø RMSE über drei zeitliche Folds 2024

in kWh · Raute je Fold, Strich ±1 Standardabweichung



Knapp vor der linearen Regression

13.272 gegen 13.643 kWh: der Wald erfasst nichtlineare Effekte.

Klar vor einfachen Regeln

3-Monats-Mittel 15.483, Vormonat 18.460 kWh.

Fold 1 ist für alle am schwersten

Mai–Jun zieht jeden Mittelwert hoch.

Ungewöhnlich ist, was 99 von 100 Fehler übertrifft

1 Abweichung messen

Nach Monatsende: Ist minus Prognose, in Volllaststunden.


2 Normale Fehler sammeln

1.397 echte Vorhersagefehler aus Nov–Dez 2024, der Größe nach sortiert.

3 Grenze ziehen

99 von 100 Fehlern liegen darunter: 144,4 VLS-h, vor 2025 eingefroren.


99 % ist der Startwert für den Pilot. Wie viele Hinweise das Team schafft, zeigt Patrick im Dashboard.



Faktor

$F = \text{Abweichung} \div 144,4 \text{ VLS-h}$ · ab $F \geq 1$ Prüfhinweis · ZL-00147: $F = 2,3$

ZL-00147: im August 2,3-mal so groß wie erlaubt



Faktor im August 2025

+2,30

Residuum 331,8 VLS-h ÷ Schwelle 144,4 VLS-h

BEWERTUNG IM COCKPIT

Messwert gültig?

Ja

Nein

Abweichung erklärt?

Ja

Nein

Ursache

Freitext

Jede Bewertung ist ein Label für später.

Aus Bewertungen wird ein Klassifikationsmodell

01

Prüfhinweise bewerten

Jede Prüfung speichert: Messwert
gültig? Abweichung erklärt?
Ursache.

02

Klassifikation trainieren

Mit genug bestätigten Fällen schätzt
ein zweites Modell je Hinweis die
Wahrscheinlichkeit in %.

03

Workflow automatisieren

Hinweise nach Wahrscheinlichkeit
automatisiert vorsortieren; der
Mensch entscheidet.

Vorbehalt

Das Modell ersetzt keine Abrechnungsentscheidung — es flaggt nur Untersuchungswürdiges.


Weiter mit Patrick: Ergebnisse 2025 und wie hinterlegte echte Zählerwerte das Retraining der Prognose verbessern.

Acht kontrollierte Kombinationen, entschieden nur in 2024

Baumtiefe	Merkmalsanteil	Min. Fälle je Blatt	CV-RMSE (kWh)	Fold-Streuung (Std., kWh)
8	0,7	5	13.272	3.843
unbegrenzt	0,7	5	13.331	3.849
8	1,0	5	13.355	3.757
unbegrenzt	1,0	5	13.422	3.729
unbegrenzt	0,7	20	13.473	4.021
8	0,7	20	13.481	4.015
8	1,0	20	13.549	3.941
unbegrenzt	1,0	20	13.565	3.923

300 Bäume, random_state = 42. Die Unterschiede sind klein; entscheidend ist die zeitliche Prüfung.

Lag-Merkmale verschieben bekannte Historie nach vorn



Januar 2024

Echter Kaltstart ohne Historie; bleibt leer.

Februar und März

Nutzen die verfügbare Historie (1 bzw. 2 Monate).

Ab April

Mittel aus bis zu drei abgeschlossenen Vormonaten.

1.453 Drei-Monats-Werte bleiben erhalten.

Warum die Schwelle aus Nov–Dez 2024 stammt

Jüngste Monate vor dem Test

November mit einem Modell aus Jan–Okt, Dezember aus Jan–Nov.

Nicht für die Modellwahl genutzt

Die Folds enden im Oktober; die Fehler sind echte Vorwärtsfehler.

Später geht nicht

Jede spätere Wahl würde 2025 selbst verwenden, also Leakage.

Kalibriert Nov–Dez 2024

144,4 VLS-h

q99 aus 1.397 Fehlern, eingefroren

Nachträglich aus 2025

175,1 VLS-h

wäre Leakage, nur zur Einordnung

Typischer Fehler (Median)

17,3 → 17,1

Kalibrierung gegen 2025: gleich groß

ML Canvas im Wortlaut von Tabelle A1 des Berichts

Nr.	Feld	Wortlaut (Bericht, Tab. A1)
01	Mehrwert	Genauere Folgemonatsplanung und monatliche Prüfung ungewöhnlicher Zählerwerte.
02	Datenquellen	Zählerverbräuche, Verträge, Kundentyp, Kalender, Wetter, Produktionsplan und Wartung.
03	Vorhersage	VLS je Zähler-Monat; Rückrechnung in kWh; große Residuen werden Prüfhinweise.
04	Merkmale	Historie, Saison, Kalender, Wetterprognose, Produktionsplan, Wartung und Kundentyp.
05	Lernansatz	Überwachte Regression; lineare Regression als Referenz, Random Forest als nichtlinearer Vergleich.
06	Evaluation	RMSE in kWh als Hauptmetrik; MAE und R^2 ergänzend; Vergleich mit zwei Baselines.
07	Entscheidung	Prognose unterstützt Beschaffung; Hinweis führt zur menschlichen Prüfung.
08	Impact	Pilot-KPIs: Fehler, Hinweisvolumen, Prüfzeit und Bestätigungsquote.
09	Zeitpunkt	Prognose vor Monatsbeginn; Residuenprüfung nach Eintreffen des Monatswerts.
10	Monitoring	Monatliche Fehler-, Drift- und Hinweiskontrolle; Retraining nur bei belegter Verschlechterung.